Proposal Riset UTS: Deteksi Audio Deepfake dengan EfficientNet-B0 dan CBAM

Nama : Deva Helal Eka Variski
NPM : 23081010313

1. Proposal Penelitian

Penelitian ini menguji apakah penambahan CBAM pada EfficientNet-B0 membuat model lebih baik dalam membedakan suara asli (Real) dan suara buatan AI (AI Generated) dari Log-Mel Spectrogram.

Judul: Deteksi Audio Deepfake Menggunakan EfficientNet-B0 dan Convolutional Block Attention Module (CBAM) Berbasis Log-Mel Spectrogram

1.1 Latar Belakang

Teknologi text-to-speech dan voice cloning kini menghasilkan suara yang sulit dibedakan dari suara manusia, dan penyalahgunaannya untuk penipuan semakin nyata. Perbedaan antara suara asli dan suara buatan terletak pada pola akustik halus yang tidak andal dikenali telinga manusia.

Representasi Log-Mel Spectrogram memungkinkan audio diperlakukan seperti citra sehingga dapat diolah oleh CNN (Khochare dkk., 2022). EfficientNet-B0 tanpa mekanisme attention terbukti lemah pada ASVspoof 2019 LA dengan EER 0,48 (Pham dkk., 2024), sedangkan CBAM yang ditambahkan pada ResNet menurunkan EER hingga 1,94% (Wu dkk., 2025). Kombinasi EfficientNet-B0, CBAM, dan Log-Mel belum banyak diuji, sehingga perlu dikaji.

Selain itu, kinerja detektor sangat bergantung pada dataset yang dipakai (Firc dkk., 2025). Karena itu penelitian ini juga menguji generalisasi pada rekaman suara asli berbahasa Indonesia yang tidak ada di data latih awal.

1.2 Rumusan Masalah

1. Bagaimana merancang model deteksi audio deepfake dengan EfficientNet-B0 dan CBAM berbasis Log-Mel Spectrogram?
2. Seberapa besar CBAM mengubah kinerja dibandingkan EfficientNet-B0 tanpa CBAM (baseline)?

3. Bagaimana kinerja model pada rekaman suara asli berbahasa Indonesia yang berasal dari luar data latih awal?

1.3 Tujuan

1. Membangun model klasifikasi biner Real vs AI Generated berbasis EfficientNet-B0 + CBAM.
2. Membandingkan model usulan dengan baseline EfficientNet-B0 pada data, preprocessing, dan hyperparameter yang identik.
3. Mengukur kemampuan model pada suara berbahasa Indonesia dan memperbaikinya dengan penambahan data.

1.4 Hipotesis

- **H0:** CBAM tidak mengubah EER secara signifikan dibanding baseline.
- **H1:** EfficientNet-B0 + CBAM menghasilkan EER lebih rendah dibanding baseline.

1.5 Manfaat

- **Akademis:** bukti empiris peran CBAM pada EfficientNet-B0 untuk deteksi audio deepfake, termasuk pada bahasa Indonesia.
- **Praktis:** dasar prototipe pemeriksa keaslian rekaman suara (Gradio) untuk membantu verifikasi rekaman yang dicurigai.

1.6 Batasan Masalah

- Klasifikasi biner (Real atau AI Generated) pada file audio, bukan deteksi real-time.
- Potongan audio 5 detik, 16 kHz, mono.
- Suara AI berasal dari sistem text-to-speech; voice conversion tidak dikaji secara khusus.
- Data berbahasa Inggris (dataset Kaggle) dan Indonesia (Common Voice + pasangan TTS).

1.7 Metode Singkat

1. **Data:** dataset Kaggle Audio Deepfake Detection + Common Voice Indonesia dan pasangan TTS-nya.
2. **Preprocessing:** mono, 16 kHz, pemangkasan hening, penyamaan durasi 5 detik, normalisasi puncak.

3. **Fitur:** Log-Mel Spectrogram (128 mel, jendela 25 ms, hop 10 ms) menjadi masukan 128 × 501.
4. **Model:** EfficientNet-B0 pretrained ImageNet sebagai backbone; CBAM ditempatkan setelah feature map terakhir.
5. **Pelatihan:** loss BCE, AdamW (lr 1e-4), cosine scheduler, early stopping, 3 seed.
6. **Evaluasi:** Accuracy, F1, AUC, EER, dan uji statistik (paired t-test) antara baseline dan model usulan.
7. **Prototipe:** antarmuka Gradio untuk mengunggah rekaman dan melihat persentase Real/AI.

2. Research Gap

Belum ada penelitian di tabel berikut yang menguji CBAM pada EfficientNet-B0 dengan masukan Log-Mel Spectrogram, dan belum ada yang menguji generalisasinya pada suara asli berbahasa Indonesia.

Penelitian	Dataset	Metode	Hasil	Celah
Khochare dkk. (2022)	Audio deepfake	CNN, TCN, STN + Mel Spectrogram	Spectrogram efektif sebagai citra	Belum memakai EfficientNet-B0 dan CBAM
Mcuba dkk. (2023)	Deepfake audio	CNN kustom, VGG-16 + MFCC, Mel, Chroma	VGG-16 terbaik pada MFCC	Belum Log-Mel + EfficientNet
Pham dkk. (2024)	ASVspoof 2019 LA	10 backbone transfer learning + ensemble	Ensemble EER 0,03; EfficientNet-B0 EER 0,48	EfficientNet-B0 tanpa attention nyaris acak
Kanwal dkk. (2024)	Fake speech	VGGish + attention block	Attention membantu deteksi	Bukan EfficientNet-B0 / CBAM
Wu dkk. (2025)	ASVspoof 2019 LA & 2015	ResNet + CBAM, raw waveform	EER 1,94%; lintas dataset 4,94%	CBAM belum diuji pada EfficientNet-B0 + Log-Mel
Shaaban & Yildirim (2025)	ASVspoof 2019 LA	Siamese CNN + self-attention	Akurasi 98%; EER 2,95%	Backbone dan fitur berbeda

Penelitian	Dataset	Metode	Hasil	Celah
Firc dkk. (2025)	Banyak dataset	Evaluasi 40 detektor	Performa sangat bergantung dataset	Generalisasi harus diuji
Setiawan dkk. (2026)	Voice deepfake	CNN + BiLSTM, spectrogram + MFCC	Akurasi 99,3%; AUC 0,9999	Belum EfficientNet-B0 + CBAM

Celah yang diisi penelitian ini

1. **Celah metode.** CBAM terbukti membantu ResNet pada raw waveform (Wu dkk., 2025), tetapi belum diuji pada EfficientNet-B0 dengan Log-Mel Spectrogram.
2. **Celah baseline.** EfficientNet-B0 tanpa attention hampir gagal pada ASVspoof 2019 LA (EER 0,48; Pham dkk., 2024). Belum jelas apakah attention mampu memperbaikinya.
3. **Celah generalisasi.** Kinerja detektor bergantung pada dataset (Firc dkk., 2025), namun pengujian pada suara asli berbahasa Indonesia belum menjadi fokus penelitian di atas.
4. **Celah perbandingan adil.** Banyak penelitian membandingkan arsitektur yang berbeda total. Penelitian ini membandingkan dua model yang identik kecuali CBAM, sehingga kontribusi CBAM terukur jelas.

Kontribusi

Penelitian ini memberi bukti empiris tentang kontribusi CBAM pada EfficientNet-B0 untuk deteksi audio deepfake, serta evaluasi generalisasi pada suara berbahasa Indonesia.

3. Dataset dan Rencana Riset Kecil

Riset kecil ini memakai dua sumber data: dataset publik Kaggle sebagai data utama berbahasa Inggris, dan Common Voice Indonesia beserta pasangan suara AI buatan sendiri sebagai data uji dan tambahan berbahasa Indonesia.

3.1 Sumber Data

Sumber	Isi	Bahasa	Peran
Kaggle "Audio Deepfake Detection Dataset" (adarshsingh0903)	Kelas Real dari LibriTTS (37 pembicara) dan kelas AI Generated	Inggris	Data latih, validasi, dan uji utama
Mozilla Common Voice Indonesia	1.500 klip suara asli (3–10 detik, maksimal 10 klip per pembicara)	Indonesia	Kelas Real tambahan dan uji generalisasi
Pasangan TTS buatan sendiri	1.500 klip AI dari kalimat yang sama dengan klip Common Voice, memakai 4 generator (MMS-TTS, gTTS, Edge TTS Ardi, Edge TTS Gadis) pada kecepatan 0,9; 1,0; 1,1	Indonesia	Kelas AI Generated tambahan

Common Voice dirilis sebagai domain publik (CC0). Suara AI dibuat dari teks kalimatnya saja, bukan dengan meniru suara kontributor.

3.2 Pembagian Data dan Preprocessing

- **Split 70/15/15** (latih/validasi/uji) dengan *speaker-independent*: pembicara yang sama tidak muncul di dua bagian. Setiap pasangan AI memakai grup pembicara klip aslinya.
- **Preprocessing:** mono, 16 kHz, pemangkasan hening (top_db 30), durasi 5 detik (potong acak saat latih, potong tengah saat uji), normalisasi puncak.
- **Augmentasi (hanya data latih, kedua kelas):** reverb, filter telepon, low-pass, dan noise putih/merah muda (SNR 8–30 dB), agar model tidak belajar jalan pintas dari kondisi rekaman.

3.3 Rencana Riset Kecil (Pilot)

Tahap	Kegiatan	Keluaran
1	Menyiapkan dataset Kaggle dan memilih 1.500 klip Common Voice	Metadata data terpilih (CSV)

Tahap	Kegiatan	Keluaran
2	Membuat 1.500 pasangan AI dengan TTS	Dataset Real/AI Indonesia
3	Split speaker-independent dan preprocessing	File split dan cache Log-Mel
4	Melatih baseline dan model usulan, masing-masing 3 seed	6 model terlatih
5	Evaluasi pada data uji Kaggle dan Common Voice	Tabel metrik dan uji statistik
6	Prototipe Gradio untuk uji rekaman sendiri	Demo yang bisa dicoba

3.4 Hasil Awal (Pilot)

Pada dataset Kaggle (durasi 5 detik, rata-rata 3 seed), CBAM cenderung lebih baik, tetapi selisihnya belum signifikan secara statistik ($p \approx 0{,}15$).

Model	Accuracy	F1	AUC	EER
EfficientNet-B0 (baseline)	0,853	0,881	0,960	0,107
EfficientNet-B0 + CBAM	0,878	0,900	0,968	0,088

Temuan penting: model yang hanya dilatih pada data Kaggle mengenali hanya 2,5–3% rekaman asli berbahasa Indonesia, sehingga data Common Voice ditambahkan. Setelah itu, pada data uji Common Voice model CBAM mencapai accuracy 0,981 dan EER 0,007, dengan 96,6% rekaman asli dikenali benar.

4. Research Mind Map



mind map penelitian · 6 cabang

Kiri adalah masukan penelitian (data, preprocessing, model), kanan adalah pengujian dan hasilnya (evaluasi, tantangan, luaran); semuanya bermuara pada satu tujuan: membedakan suara Real dan AI Generated.

5. Rencana Evaluation Metric

Metrik utama adalah EER, karena tidak bergantung pada satu ambang keputusan. Accuracy, F1, dan AUC melengkapinya, dan hasil ditampilkan terpisah untuk data Kaggle dan Common Voice.

Kelas positif = AI Generated. TP = AI terdeteksi AI, TN = Real terdeteksi Real, FP = Real salah terdeteksi AI, FN = AI salah terdeteksi Real.

Metrik	Rumus	Arti	Alasan dipakai
Accuracy	(TP + TN) / (TP + TN + FP + FN)	Proporsi prediksi yang benar	Gambaran umum, mudah dibaca

Metrik	Rumus	Arti	Alasan dipakai
Precision	TP / (TP + FP)	Dari yang diprediksi AI, berapa yang benar AI	Menunjukkan seberapa sering suara asli dituduh AI
Recall (ai_ok)	TP / (TP + FN)	Dari semua suara AI, berapa yang tertangkap	Menunjukkan kemampuan menangkap deepfake
Specificity (real_ok)	TN / (TN + FP)	Dari semua suara asli, berapa yang dikenali asli	Mengungkap bias model terhadap suara asli
F1-score	2 × Precision × Recall / (Precision + Recall)	Keseimbangan precision dan recall	Cocok bila kelas tidak seimbang
AUC-ROC	Luas di bawah kurva ROC	Kemampuan memisahkan dua kelas di semua ambang	Tidak bergantung pada ambang 0,5
EER	Titik saat FPR = FNR	Tingkat kesalahan saat kedua jenis salah sama besar	Standar di bidang deteksi spoofing; memungkinkan perbandingan dengan jurnal acuan

```
FPR = \frac{FP}{FP + TN}, \qquad FNR = \frac{FN}{FN + TP}, \qquad EER = FPR = FNR
```

Protokol evaluasi

1. **Pemilihan model** memakai EER pada data validasi, bukan data uji.
2. **Data uji dilaporkan per domain:** uji Kaggle, uji Common Voice, dan gabungan.
3. **Tiga seed** (42, 123, 2026) untuk baseline dan model usulan; hasil dilaporkan sebagai rata-rata.
4. **Uji signifikansi:** paired t-test pada EER antar seed; selisih dianggap signifikan jika $p < 0,05$.
5. **Pembanding:** baseline EfficientNet-B0 tanpa CBAM dan hasil pada jurnal acuan (dengan catatan dataset berbeda).

6. Usulan Jadwal dan Rujukan

Riset kecil ini dapat diselesaikan dalam 8 minggu mengikuti tahap pada bagian 3.3.

Minggu	Kegiatan
1	Studi literatur dan penyiapan dataset Kaggle
2	Pemilihan klip Common Voice dan pembuatan pasangan TTS
3	Split speaker-independent, preprocessing, cache Log-Mel
4–5	Pelatihan baseline dan EfficientNet-B0 + CBAM (3 seed)
6	Evaluasi, uji signifikansi, analisis kesalahan
7	Pembuatan prototipe Gradio
8	Penyusunan laporan dan presentasi

Rujukan yang dikutip

Khochare dkk. (2022); Mcuba dkk. (2023); Pham dkk. (2024); Kanwal dkk. (2024); Wu dkk. (2025); Shaaban & Yildirim (2025); Firc dkk. (2025); Setiawan dkk. (2026). Tuliskan format lengkapnya (judul, jurnal, DOI) sesuai daftar pustaka pada draf Bab II.